

ECES AI Bot — Task per Claude Code

Integrazione Open WebUI + Ollama + ECES API

Data: maggio 2026 | VM: epepostgresdb (10.158.251.79) | Ambiente: ISPRA

1. Obiettivo del Task

Migliorare e completare l'integrazione tra Open WebUI, Ollama e il sistema ECES (EURING Code Evaluation System) già parzialmente configurata sulla VM ISPRA. Il bot deve diventare un esperto autonomo di inanellamento ornitologico scientifico europeo, capace di riconoscere, interpretare e convertire stringhe EURING usando le API ECES reali.

2. Stato Attuale dell'Installazione

2.1 Infrastruttura

Componente	Stato	Dettagli
Ubuntu 22.04 LTS	✓ Attivo	VM ISPRA, 7.8 GB RAM (ampliamento a 16 GB richiesto)
Docker 29.5.0	✓ Installato	Con Docker Compose plugin
Ollama	✓ Attivo	CPU-only, porta 11434 su 0.0.0.0
qwen2.5:3b	✓ Scaricato	Modello temporaneo, verrà sostituito con 14b
Open WebUI	✓ Attivo	Docker container, porta 3000, http://10.158.251.79:3000
ECES Backend FastAPI	✓ Attivo	/opt/eces/, porta 8000, 4 workers, utente eces
PostgreSQL ECES	✓ Attivo	DB: eces_analytics, user: eces_user

2.2 Configurazione Open WebUI

- Connessione Ollama: http://172.17.0.1:11434 (gateway Docker bridge)
- Autenticazione Ollama: Bearer ollama-local
- Modello custom creato: ECES Bot (basato su qwen2.5:3b)
- Strumenti configurati: eces_recognize, eces_convert (con autenticazione JWT)
- System prompt EURING: configurato con conoscenza versioni 1966/1979/2000/2020

2.3 Autenticazione ECES API

Le API ECES richiedono autenticazione JWT. Il flusso attuale negli strumenti Open WebUI è:

```
POST http://172.17.0.1:8000/api/auth/login → {username: admin, password: admin}
```

```
Response: {access_token: <JWT>, expires_in: 28800}
Header: Authorization: Bearer <token>
```

Il token dura 8 ore. Gli strumenti attualmente eseguono il login ad ogni chiamata (inefficiente ma funzionale).

3. Problemi Aperti da Risolvere

3.1 Tool Calling Instabile

Il modello qwen2.5:3b attiva gli strumenti ECES solo se esplicitamente richiesto dall'utente con frasi come 'usa lo strumento eces_recognize'. Con domande naturali tende a rispondere a memoria senza chiamare le API.

- Causa: modello 3B troppo piccolo per tool calling autonomo affidabile
- Soluzione primaria: upgrade a qwen2.5:14b quando arrivano 16 GB RAM
- Soluzione secondaria: rafforzare il system prompt con istruzioni RULE assolute

3.2 Token JWT non Cachato

Gli strumenti Open WebUI eseguono un login ECES ad ogni chiamata. Sarebbe più efficiente cachare il token per 8 ore.

- Implementare un meccanismo di caching del token nelle Tools class
- Gestire il refresh automatico prima della scadenza

3.3 System Prompt da Arricchire

Il system prompt attuale copre le basi EURING ma manca di:

- Tabelle complete dei codici specie EURING (almeno le specie comuni italiane)
- Codici età (pullus, juvenile, adult, ecc.) con descrizioni
- Codici modalità di cattura (mist net, trap, ecc.)
- Esempi di stringhe reali per ogni versione (1966, 1979, 2000, 2020)
- Logica di interpretazione dei campi biometrici (unità di misura)

3.4 CORS ECES non Configurato per Open WebUI

Il file /opt/eces/backend/main.py potrebbe non includere http://172.17.0.1 nelle origini CORS autorizzate. Verificare e aggiungere se necessario.

4. Task Richiesti a Claude Code

4.1 [PRIORITÀ ALTA] Ottimizzare gli Strumenti Open WebUI

File da modificare: gli strumenti sono configurati direttamente nell'interfaccia Open WebUI (Workspace → Strumenti). Esportarli e salvarli come file Python per versioning.

Implementare caching JWT:

```
class Tools:
    _token = None
    _token_expiry = 0
    def _get_token(self) -> str:
        import time
        if not self._token or time.time() > self._token_expiry - 300:
            # refresh token
        return self._token
```

4.2 [PRIORITÀ ALTA] Aggiungere Strumento eces_batch_recognize

Aggiungere un terzo strumento per il riconoscimento batch (fino a 1000 stringhe):

```
POST http://172.17.0.1:8000/api/euring/batch/recognize
Body: {"strings": ["stringa1", "stringa2", ...]}
```

4.3 [PRIORITÀ MEDIA] Arricchire il System Prompt

Creare un system prompt esteso con:

- Tabella codici specie EURING per uccelli comuni italiani ed europei
- Tabella completa codici età EURING (1=pullus, 2=juvenile, 3=adult, ecc.)
- Tabella codici sesso (1=M, 2=F, 3=?, 4=intersex, 9=unknown)
- Tabella modalità di cattura
- 4 esempi di stringhe reali, una per versione
- Istruzioni esplicite: SEMPRE chiamare eces_recognize prima di analizzare

4.4 [PRIORITÀ MEDIA] Verificare e Fixare CORS ECES

Verificare il file /opt/eces/backend/main.py e aggiungere le origini mancanti:

```
allow_origins=[
    "http://10.158.251.79:3000",    # Open WebUI
    "http://172.17.0.1:3000",      # Docker gateway
    "http://localhost:3000",       # locale
]
```

4.5 [PRIORITÀ BASSA] Script di Avvio Automatico

Creare uno script systemd o cron per garantire che Open WebUI si riavvii automaticamente dopo un reboot della VM, verificando anche che ECES e Ollama siano attivi prima di partire.

5. Architettura Attuale

Servizio	Porta	Note
ECES Backend FastAPI	8000	Host: 0.0.0.0, 4 workers uvicorn, /opt/eces/venv

PostgreSQL	5432	DB: eces_analytics, user: eces_user, pw: eces_secure_2024
Ollama	11434	Host: 0.0.0.0, OLLAMA_API_KEY=ollama-local
Open WebUI	3000	Docker container, OLLAMA_BASE_URL=http://172.17.0.1:11434

Docker Compose file: /home/amministratore/eces-ai/docker-compose.yml

Ollama override: /etc/systemd/system/ollama.service.d/override.conf

ECES config: /opt/eces/ispra_config.env

6. Note per Claude Code

- La VM è accessibile solo via FortiClient VPN ISPRA o dalla rete interna
- L'utente amministratore ha sudo sulla VM
- Il servizio ECES gira come utente 'eces' (non root) — modifiche a /opt/eces/ richiedono sudo
- Quando arriveranno 16 GB RAM: eseguire 'ollama pull qwen2.5:14b' e aggiornare il modello in ECES Bot
- Il repository ECES è su GitHub: <https://github.com/DavideLicheri/Semantic-EPE> (privato)
- Credenziali ECES API: admin / admin (da cambiare in produzione)
- Il bot risponde in italiano per default (configurato in SOUL.md e system prompt)